



Paul-Antoine BISGAMBIGLIA – <u>bisgambiglia pa@univ-corse.fr</u>
Marie-Laure NIVET – <u>nivet ml@univ-corse.fr</u>
Evelyne VITTORI - <u>vittori@univ-corse.fr</u>

Objectifs de ce cours




- Vous donner les connaissances minimales pour réaliser les exercices de l'atelier 4
- Maîtriser la particularité des chaines de caractères en python
- Vous initiez à l'utilisation d'expressions régulières pour effectuer des recherches

Plan du cours Chaînes de caractères

- Les chaines de caractères en python
- Les expressions régulières
- Les fichiers de texte





OPEN TOOLS FOR SCIENTISTS.



Chaînes de caractères en python

Première entrée dans le mode objet de python



Les chaînes de caractères


- Objets de la classe str (ou string)
- Objets immutables
 - non modifiables
 - Listes particulières car non modifiables
- Objets indexables
- Objets itérables


Notion d'objet immutable

 Les chaines de caractères sont des objets qui ne peuvent pas être modifiés, ils sont dits « immutables »

Si l'on tente de les modifier une nouvelle

instance est créée.





Méthodes de la classe str

Méthodes m applicables sur une chaine c : c.m()

- lower() upper()
 - renvoie le texte transformé en minuscules (resp. en majuscules)
- t="bonjour"
 print(t[0].upper()+t[1:])
 - retourne met la chaîne avec la première lettre en majuscule
- endswith(suffixe[, debut[, fin]])
 - retourne True si la chaine se termine par suffixe, et False sinon
 - suffixe peut aussi être un tuple de suffixes
 - le test peut débuter à debut et se terminer à fin

Exemple de Manipulation d'une chaine

```
def remplacer_car(ch:str,num:int,c:char)->str:
#renvoie la chaine ch dans la quelle le caractère d'indice num est
remplacé par le caractère c
```

```
ch[num-1]=c
TypeError: 'str' object does not support item assignment
return ch
```

```
#Test
t= "bonjour"
r=remplacer_car(t,4,"p")
print(r)
```



Attention!!

Ne pas oublier que les chaines sont immutables ch ne peut pas être modifiée!!

Exemple de Manipulation d'une chaine

```
#Test
t= "bonjour"
r=remplacer_car(T,4,"p")
print(R)
```

Exemples de Parcours d'une chaine

```
def affiche_car(ch:str) :
    #affiche les caractères de la chaine ch de manière verticale
    for c in ch :
        print(c)
```

```
def o_majuscules(ch:str):
#renvoie la chaine Ch en remplaçant les « o » par des « O »

ch_res=""
for c in ch:
    if c=='o':
        ch_res+= c.upper()
    else:
        ch_res+= c

return ch res
#Test
t= "bonjour"
affiche_car(t)
r=o_majuscules(t)
print(r)

#Test
t= "bonjour"
affiche_car(t)
r=o_majuscules(t)
print(r)
```

Méthodes

Attention! la chaine d'origine n'est pas modifiée!!

- replace(c1:str, c2:str)->str:
 - renvoie la chaine d'origine dans laquelle la souschaine c1 a été remplacée par la chaine c2 dans la chaine
- count(c:str)->int :
 - renvoie le nombre d'occurrences de la sous-chaine c dans la chaine

Méthodes de test de caractères

- isalpha()-> booléen:
 - renvoie True si la chaine n'est composée que de caractères alphabétiques (lettres)
- isdecimal()-> booléen:
 - renvoie True si la chaine n'est composée que de caractères décimaux(chiffres)
 - isdigit() et isnumeric() fonctionnent de manière similaire mais incluent également les nombres exprimés avec des caractères spéciaux
 - ex: '\u00BD' index caractère unicode ½

Méthodes de test de caractères

- isspace()->booléen:
 - renvoie True si la chaine n'est composée que d'espaces
- strip([chars:str])-> str:
 - renvoie une chaine dans laquelle les caractères apparaissant dans chars sont supprimés
 - si chars est omis, les espaces sont supprimés

Méthodes

- split([séparateur]) : liste de chaines
 - renvoie une liste de mots extraits de la chaine

```
animaux = "girafe:tigre:singe"
print(animaux.split(":") )
# affiche ['girafe', 'tigre', 'singe']
```

séparateur par défaut: espace ou tabulation

- expandtab([nbCar]): chaine
 - renvoie une copie de la chaine dans laquelle les caractères de tabulation (\t) ont été remplacés par des espaces en fonction du nombre de caractères par colonne (nbCar=8 par défaut)

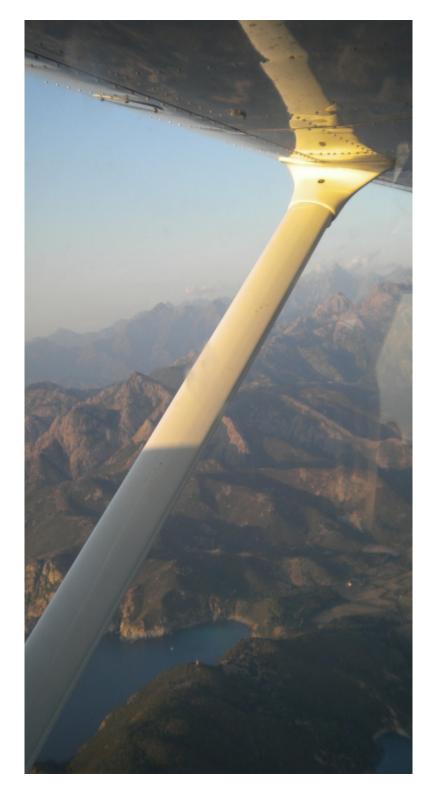
Méthodes

attention L ne doit contenir que des chaînes de caractères

- join(lst:list)->str:
 - transforme une liste (un itérable) en une chaîne de caractère en ajoutant le séparateur spécifié entre chaque mot de la liste

chaineSeparateur.join(l)

```
l=['girafe', 'tigre', 'singe']
res="-".join(l)
#renvoie la chaine 'girafe-tigre-singe'
res=" ".join(l)
#renvoie la chaine 'girafe tigre singe'
```



Expressions régulières


Expressions régulières

WHENEVER I LEARN A
NEW SKILL I CONCOCT
ELABORATE FANTASY
SCENARIOS WHERE IT
LETS ME SAVE THE DAY.















Existent dans la plupart des langages de programmation

Expressions régulières

- Une expression régulière (regex) est une chaîne de caractère qui spécifie le format d'un ensemble de chaînes de caractères
- Elle utilise des symboles qui ont une signification particulière:
 - . ^ \$ * + ? { } [] \ | ()

Interêts
Recherches et
Modifications concises

Regexp	chaines correspondantes
corte	« corte » « universite de corte » « ville de corte » « cortenais »
cort*	« corte » « universite de corte » « ville de corte » « cortenais » « corps »
^cort+e	« corte » « cortenais » « cortte »

Caractères spéciaux

Caractère	Signification				
	n'importe quel caractère sauf retour chariot				
['a','b', 'c']	un caractère appartenant à l'énumération				
[^'a', 'b']	Tous les caractères sauf ceux énumérés				
^	début de la chaine, la ligne				
\$	fin d'une chaine, ligne				
 (a b)	alternative - ou reconnaît l'un ou l'autre				
()	désigne un groupe de caractères pouvant se répéter				
*	0, 1 ou plusieurs occurrences du caractère qu'il suit				
+	1 ou plusieurs occurrences du caractère qu'il suit				
?	0 ou 1 occurrence du caractère qui suit				

Répétitions de caractères

```
suite de caractères

Sequence{ nb1,nb2}
```

- A{2}: la lettre A (en majuscule) se répète 2 fois consécutives.
- BA{1,9}: la séquence BA se répète de 1 à 9 fois consécutives.
- BRA{,10}: BRA n'est pas présent du tout ou présent jusqu'à 10 fois consécutives.
- VO{1,}: VO est présent au moins une fois.

Un petit exercice

GR(A)?S	GRAS	TRUE	FALSE	TRUE
GR(A)?S	GRS	TRUE	FALSE	TRUE
M(.)+N	MAISON	TRUE	FALSE	TRUE
M(.)+(O)+N	MAISON	TRUE	FALSE	TRUE
M(.)+([a-z])+N	MAISON	TRUE	FALSE	FALSE
M(.)+([A-Z])+N	MAISON	TRUE	FALSE	TRUE
^!	!MAISON!	TRUE	FALSE	TRUE
!MAISON	!MAISON!	TRUE	FALSE	TRUE
^!MAISO!\$!MAISON!	TRUE	FALSE	FALSE
^!MAISON!\$!MAISON!	TRUE	FALSE	TRUE
^!M(.)+!\$!MAISON!	TRUE	FALSE	TRUE
([0-9])	03 88 00 00 00	TRUE	FALSE	TRUE
^0[0-9]([/]?[0-9]{2}){4}	03 88 00 00 00	TRUE	FALSE	TRUE
^0[0-9]([/]?[0-9]{2}){4}	03/88/00/00/00	TRUE	FALSE	TRUE
^0[0-9]([/]?[0-9]{2}){4}	03_88_00_00_00	TRUE	FALSE	FALSE

Caractères et séquences d'échappement

- Caractère d'échappement
 - un caractère placé devant un caractère spécial (ou une séquence) dans le but d'éviter son interprétation
- Séquence d'échappement
 - séquence constituée d'un caractère d'échappement suivi des caractères qu'il modifie

Caractères et séquences d'échappement

- est un caractère d'échappement
 - \\ représente le caractère '\'
 - \\n représente la séquence de caractères '\' and 'n'
- En python, pour plus de visibilité, on utilise le caractère r placé avant une expression spéciale
 - r"\n" représente la séquence de caractères '\' and 'n'

Séquences d'échappement spéciales

- \d: uniquement des chiffres (équivalent à [0-9])
- D: aucun chiffre (équivalent à [^0-9]).
- \s: un espace (équivalent à[\t\n\r\f\v]).
- \S: aucun d'espace (équivalent à[^ \t\n\r\f\v]).
- w: uniquement des caractères alphanumériques (équivalent à [a-zA-Z0-9_]).
- \W: aucun caractère alphanumérique (équivalent à [^a-zA-Z0-9_]).

Expressions régulières (en python)

- Bibliothèque python re
- Fonctions: findall, search, match, sub
- Classe Regex:
 - Objet expression régulières
 - Méthodes: findall, search, match, sub
- Classe match Object:
 - objet résultat de l'application d'une regex sur une chaine
 - Méthodes: group, groups

Fonctions de recherche

- findall(regex, chaine) : liste de chaines
 - renvoie une liste contenant toutes les sous chaines qui vérifient l'expression régulière
 - None si regex n'est pas trouve

```
print(re.findall("([0-9]+)", "Bonjour 111 Aurevoir 222"))
#affiche ['111', '222']
```

Fonctions de recherche

split(regex, chaine) : liste de chaines

séparateurs

- renvoie une liste contenant toutes les sous chaines délimitées par les occurrences de la regex
- None si regex n'est pas trouve

```
print(re.split("[\s,;]+", "Bonjour; Aurevoir; adieu"))
# affiche ['Bonjour', 'Aurevoir', 'adieu']
```

Fonctions de recherche

search(regex, chaine) : Match Object

Objet de la classe sre.SRE Match

- renvoie un match object correspondant à l'application de la regex sur la chaine
- None si aucune correspondance n'est trouvée
- match(regex, chaine): idem mais la recherche ne s'effectue qu'à partir du début de la chaine

```
chaine = ""
expression = r''^0[0-9]([.-]?[0-9]{2}){4}$"
while re.search(expression, chaine) is None:
   chaine = input("Saisissez un numéro de téléphone (valide):")
```

Test de la validité d'un numéro de téléphone

Fonction de remplacement

- sub(regex, rempl,chaine, nb): chaine
 - renvoie une chaine dans laquelle nb occurrences des sous-chaines de chaine qui vérifient regex sont remplacées par la chaine rempl
 - si regex comporte des groupes: renvoie une liste de tuples
 - si nb=0 ou est omis: toutes les occurrences sont remplacées


```
c="Bonjour * Vous êtes trés gentil *"
print(re.sub(r"(\*)","Monsieur Dupont",c))
# affiche
# Bonjour Monsieur Dupont Vous êtes trés gentil Monsieur Dupont
```

Groupes

- Permettent de décomposer une expression
- Utiles pour les remplacements
- Les groupes sont numérotés à partir de 1

Groupe 1
$$\rightarrow$$
 (a) b (cd) \rightarrow Groupe 2

On peut également les nommer: (?P<nomGroupe>...)



Utilisation des groupes

```
phrase="Bonjour Marie de Corte"
res=re.search(r"Bonjour (?P<nom>\w+) de
(?P<adresse>\w+)", phrase)
print(res.group('nom') + " -" + res.group('adresse'))
#affiche Marie - Corte
```

Regex compilées

- Il est possible de compiler une regex pour ensuite l'appliquer sur plusieurs chaînes
- compile(regex) : object regex
 - renvoie un objet regex associé à la regex transmise en paramètre


```
chn_mdp = r"^[A-Za-z0-9]{6,}$"
exp_mdp = re.compile(chn_mdp)
mot_de_passe = ""
while exp_mdp.search(mot_de_passe) is None:
    mot_de_passe = input("Tapez votre mot de passe : ")
```



Fichiers en python

Généralités
Fichiers binaires
Fichiers de texte

Notion de fichier



- Rôle fondamental en informatique: besoin de persistance des données
- Premier moyen de stockage « logique » des données
- Unique solution avant l'apparition des bases de données
- Mais les bases de données utilisent des fichiers!!

Notion de fichier: deux niveaux de définition

- Niveau physique (système d'exploitation):
 - Suite d'octets stockée sur un support

physique permanent et repérée par un nom

- Niveau logique (applications):
 - Suite de données mémorisée de manière persistante
 - Différents types de fichiers selon :
 - la nature des données stockées
 - les manipulations envisagées



Types de fichiers

- Au niveau physique, tous les fichiers sont des suites d'octets.
- Au niveau logique, on distingue deux types selon la manipulation :
 - Fichiers « binaires »: suites d'octets indifférenciés



 Fichiers « de texte »: suites de caractères lisibles dans un éditeur de texte encodage/décodage automatique


Car1	Car2	Car3	Car4				Carm
------	------	------	------	--	--	--	------

Fichiers de texte

- Suites de caractères
- Associés à un standard d'encodage de caractères : tables associant chaque caractère à un ou plusieurs octets

fichiers dits « ASCII »

- Exemple
 - codage UNICODE : 1 caractère = 2 octets



Types d'encodages de caractères

ASCII : standard américain

Pour plus de détails http://www.alsacreations.com/astuce/lire/83codages-ascii-latin1-etc.html

- 128 caractères (pas de lettres accentuées ...)
- ISO-8859-1 ou Latin-1
 - Extension de l'ASCII (191 caractères dont les accents!)
 - ISO-8859-15 ou Latin-9 (extension avec œ et €)
- Codage cp1252
 - Extension de ISO-8850-1 (218 caractères)

Codage windows par défaut

- Codage UTF-8
 - le plus général (famille du standard Unicode)
 - codage sur 1 à 4 octets
 - utilisé par 87.6% en 2016 des sites web

Codage Unix -Linux par défaut

Types de fichiers de texte

- Fichiers de texte simples :
 - Suite de caractères organisés en lignes (repérées par un caractère « retour chariot »)
- Fichiers de textes structurés avec balises
 - Chaque donnée élémentaire est encadrée par un balisage
 - fichiers HTML, XML, Latex, etc.
- Fichiers d'enregistrements
 - Contient des enregistrements (valeurs de type structurée)
 - ex= nom, age, adresse

Exemples de fichiers d'enregistrements

Paoli;Pasquale;0495156487;ubabbu@yahoo.fr

Bonaparte; Napoleon; 0156912347; empereur@free.fr

LeGrand; Alexandre; 0289765194; alegrand@free.fr

DeGaulle; Charles; 0149875231; cdg@aol.fr

enregistrements en lignes séparateur;

Occupation optimisée de l'espace

Gestion complexe

Paoli	Pasquale	0495156487	ubabbu@yahoo.fr
Bonaparte	Napoleon	0156912347	empereur@free.fr
LeGrand	Alexandre	0289765194	alegrand@free.fr
DeGaulle	Charles	0149875231	cdg@aol.fr

enregistrements en lignes champs de largeur fixe


- ■Perte de place
- Traitements facilités

Fichiers binaires

- Désigne tout fichier contenant autre chose que des caractères:
 - fichier image (bitmap)
 - fichier de son
 - fichier pdf
 - •
- Données <u>non lisibles directement</u>
- Nécessite un programme spécifique pour être lu et exploité.
- Plus compact et plus rapide à lire/écrire

Modes d'accès aux données

- Accès séquentiel :
 - On accède au contenu dans l'ordre du stockage
 - Pour lire la valeur v_n il faut avoir lu les valeurs v_1 à v_{n-1}



valeur=octet ou caractère


Possible pour tout type de fichier

Modes d'accès aux données

Accès direct :

accés dit « aléatoire » (random)


 On accède directement au ième octet du fichier



- Toujours possible pour les fichiers binaires :
 - Acces direct au ième octet

Principes de manipulation d'un fichier


 Un indicateur de position (curseur de parcours) indique la position courante.



- Une position particulière: fin de fichier
 - EOF : End of File
 - En général, une fonction booléenne permet de savoir si la position EOF est atteinte par le curseur

Etapes de manipulations d'un fichier

1. Ouverture du fichier



2. Lectures/Ecritures dans le fichier

3. Fermeture du fichier

Fichiers en python

- Un fichier en python est un objet de la classe Fichier:
 - Manipulation par les méthodes de la classe Fichier
- La distinction fichier de texte/fichier binaire est définie lors de l'ouverture du fichier:
 - paramètre mode de la méthode open
 - t (texte) mode par défaut
 - b(binaire) à préciser de manière explicite
- La manipulation d'un fichier en python passe par les étapes classiques.

Ouverture d'un fichier

- open(nomfic, mode, encoding) : objet fichier
 - Renvoie un objet fichier associé au fichier nomfic
 - mode d'ouverture
 - r : lecture seule (valeur par défaut)

Après ouverture, le curseur est en position 0

- w : écriture seule (<u>écrasement</u> du fichier existant de même nom; si le fichier n'existe pas, il est créé)
- a: ajout en fin de fichier (si le fichier n'existe pas, il est créé)
- x: crée un nouveau fichier et l'ouvre en écriture
- r+, w+, a+ : lecture et écriture (mode modification)
- encoding: par défaut cp1252 sous windows et UTF8 sous Unix/Linux

uniquement pour les fichiers de texte

Ouverture d'un fichier

- Par défaut, le fichier est ouvert en mode texte (t)
- Il faut ajouter b aux différents modes pour l'ouvrir en mode binaire (lecture/écriture d'octets et non de caractères)
 - rb: ouverture en mode lecture binaire
 - wb: ouverture en mode écriture binaire
 - ab: ouverture en mode ajout binaire
 - rb+, wb+ ou ab +: lecture et écriture binaire

Particularité des fichiers binaires

- Intérêt:
 - lecture octet par octet ou blocs d'octets.
 - accés direct possible.
- Opérations de lectures/écriture nécessitant un decodage/encodage explicite.
- Utilisation des méthodes read/write avec des paramètres ou résultats de type tableau d'octets (bytes)

Ouverture d'un fichier

- Après l'exécution de la méthode open:
 - mode r,w : curseur positionné à 0
 - mode a : curseur positionné à la fin du fichier

Fichier python curseur

Octet1 Octet2 Octet3 Octetn

Si le curseur est en position i, une opération de lecture lira l'octet i+1

Encodage/Decodage de caractères

- méthode encode(chaine, typEncodage):
 tableau d'octets
 - renvoie la liste d'octets correspondant à la conversion de la chaine de caractère chaine
- méthode decode(tabOct, typEncodage):chaine
 - renvoie la chaine de caractères correspondant à la conversion du tableau d'octets tabOct

Autres fonctions utiles:

cf.fichiers binaires

- ord(ca) renvoie le code du caractère ca
- chr(co) renvoie le caractère de code co

Lecture d'un fichier

- read([nbCar/nbOctets]) : chaine
- Le curseur est déplacé de nbCar/nbOctets
- Fichier de texte: renvoie une chaîne de caractères correspondant à nbCar caractères lus dans le fichier à partir de la position du curseur
- Fichier binaire: Renvoie un tableau d'octets de nbOctets lus à partir de la position du curseur
- si nbCar est omis ou <0: renvoie l'intégralité du fichier

Lecture d'un fichier de texte

- readLine() : chaine
 - Renvoie une seule ligne du fichier à partir de la position du curseur
 - la ligne se termine par le caractère \n sauf si c'est la dernière
 - Renvoie la chaine vide si fin de fichier
- readLines() : liste de chaines
 - Renvoie toutes les lignes du fichier à partir de la position du curseur dans une liste avec une ligne par élément

Manipulation du curseur de position

- tell(): entier Renvoie 0 quand le fichier vient d'être ouvert
 - Renvoie la position courante du curseur dans le fichier mesurée en nombre d'octets depuis le début du fichier
 attention : le nombre d'octets n'est
- seek(nbOctets, pos)
- pas toujours égal au nombre de caractères
- déplace le curseur du fichier de nb octets
- à partir de :
 - du début si pos=0
 - de la position courante si pos=1
 - de la fin du fichier si pos=2

Interessant pour les fichiers binaires

Ecriture dans un fichier

- write(texte/tabOct): entier
 - écriture de la chaine de caractères texte (ou du tableau tabOct) dans le fichier à partir de la position du curseur
 - Si ouverture en mode w: écriture en écrasant le contenu existant
 - Si ouverture en mode a : écriture à la fin du fichier
 - renvoie le nombre de caractères (octets) écrits

Pour définir des lignes, il faut explicitement insérer les caractères de saut de ligne \n

Fermeture d'un fichier

close()

 ferme le fichier et libère toutes les ressources utilisées

closed

 attribut indiquant si le fichier est ouvert (True) ou fermé(False)

Instruction with

- Permet une fermeture propre des ressources
 - L'appel à close() est fait automatiquement

```
with open("profs.txt" , r) as f :
    print(f.read())
```

Lecture globale d'un fichier de texte (avec read)

```
# ouverture du fichier en lecture (r=read)
f=open("profs.txt","r")
tout=f.read() #variable de type chaine de caractères
print("** Contenu du fichier **")
print(tout)
print("** fin **")
                                  Contenu du fichier **
                               Simonnet
tout est de type
     string
```

Lecture globale d'un fichier de texte (avec readlines)

```
# ouverture du fichier en lecture
f=open("profs.txt","r")
listeTout=f.readlines()
print("** Contenu du fichier **")
print(listeTout)
print("** fin **")
```

```
** Contenu du fichier **
['Simonnet\n', 'Nivet\n', 'Vittori\n', 'Poggi\n', 'Cagnard']
** fin **
```

liste Tout est de type liste de string

Lecture ligne par ligne avec readline

```
# ouverture du fichier en lecture
                                     Simonnet
f=open("profs.txt","r")
c=f.readline()
                                     Nivet
print("** Contenu du fichier **")
Vittori
while c!="":
                                     Poggi
       print(c)
       c=f.readline()
print("** fin **")
                                            Les \n sont conservés
                                             et donc affichés d'où
#autre écriture plus concise
                                                les lignes vides
for ligne in f:
       print(ligne)
                                                              60
```

Fichier d'enregistrements à longueur variable

Exemple de fichier

Utilisation de séparateurs (ici ;)

Simonnet;0610142522

Nivet;065255555

Vittori;0688888888

Poggi;061455555

Cagnard;0689999999

Accès séquentiel à un enregistrement

```
def lireProf(f, indice):
    #renvoie une chaine de caractère représentant le prof numéro "indice"
    dans le fichier f
    #l'enregistrement est supposé présent
    f=open(f,"r") # ouverture du fichier en lecture
    #lecture de indice-1 enregistrements
    for i in range(1,indice):
         f.readline()
    #lecture de l'enregistrement indice
                                           "Nivet;065255555/n"
    prof=f.readline()
    #création d'une liste avec une valeur par champ
    lprof=prof.rstrip().split(";")
                                           ['Nivet', '065255555']
    return lprof
```

rstrip([chars]) : élimine les caractères situés en fin de ligne (par défaut \n)

split([séparateurs]): renvoie une liste de chaines selon les séparateurs

Manipulation binaire d'un fichier

```
# ouverture du fichier profs en mode lecture/ecriture binaire)
f = open('profs','bw+')
# écriture de la chaine « Simonnet » après encodage
f.write("Simonnet".encode("utf8"))
#positionnement au début du fichier
f.seek(0)
#lecture intégrale du fichier
                                         t est de type bytes
t=f.read () ←
                                         (tableau d'octets)
#affichage des octets lus après décodage
print(t.decode("utf8")) _
                                          Simonnet
#fermeture du fichier
f.close()
```

Le module struct contient des fonctions facilitant le codage/décodage d'un fichier binaire